

Análisis Exploratorio de Datos (EDA) Agrícola: Análisis Municipio a Municipio y sus Varios Cultivos (2015-2024)

Departamento: Valle del Cauca

Enfoque Estructural: El análisis se efectúa **municipio a municipio**, y **dentro de cada municipio se examinan sus varios cultivos** mediante subplots e identificadores visuales individuales.

Cálculos de Rentabilidad y Depuración:

- **Filtro de Rendimiento:** $0 < \text{Rendimiento} \leq 100 \text{ Ton}/\text{Ha}$ para depurar ceros y distorsiones atípicas.

```
In [1]: import os
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')

# Configuración visual
sns.set_theme(style="whitegrid", palette="muted")
plt.rcParams["figure.figsize"] = (12, 6)

# Carga de datos
data_sources = [
    Path('../data/silver_agri_modelo_base.csv'),
    Path('data/silver_agri_modelo_base.csv'),
    Path('../data/dataset_prediccion_rentabilidad.csv'),
    Path('data/dataset_prediccion_rentabilidad.csv'),
    Path('../data/dataset_consolidado_valle.csv'),
    Path('data/dataset_consolidado_valle.csv')
]
data_path = next((p for p in data_sources if p.exists()), Path('data/dataset'))
print(f"Cargando dataset desde: {data_path}")

df_raw = pd.read_csv(data_path)

renames = {
    "nombre_cultivo": "cultivo",
    "precio": "precio_promedio_anual_sipsa",
    "indice_oni": "promedio_oni",
    "oni": "promedio_oni",
    "rendimiento_t_ha": "rendimiento_toneladas_ha",
    "id_municipio": "codigo_municipio",
}
df_raw = df_raw.rename(columns={k: v for k, v in renames.items() if k in df_
```

```

if "cultivo" in df_raw.columns:
    df_raw["cultivo"] = df_raw["cultivo"].astype(str).str.strip().str.title()

# Mapear municipio si solo existe codigo_municipio
if ("municipio" not in df_raw.columns or df_raw["municipio"].isnull().all())
    mun_path = Path('../data/municipios_valle_clean.csv') if Path('../data/m
    if mun_path.exists():
        df_mun_map = pd.read_csv(mun_path)[["codigo_municipio", "municipio"]
        df_raw = pd.merge(df_raw, df_mun_map, on="codigo_municipio", how="le
    else:
        cons_path = Path('../data/dataset_consolidado_valle.csv') if Path('.
        if cons_path.exists():
            df_cons = pd.read_csv(cons_path)[["codigo_municipio", "municipi
            df_raw = pd.merge(df_raw, df_cons, on="codigo_municipio", how="l

if "municipio" not in df_raw.columns:
    df_raw["municipio"] = "Valle del Cauca"
else:
    df_raw["municipio"] = df_raw["municipio"].astype(str).str.strip().str.ti

crops_path = Path('../data/cultivos_valle.csv') if Path('../data/cultivos_va
if "produccion_toneladas" not in df_raw.columns and crops_path.exists():
    df_crops = pd.read_csv(crops_path)
    cols_to_add = [c for c in ["produccion_toneladas", "rendimiento_tonelada
    if cols_to_add and "cultivo" in df_raw.columns and "municipio" in df_raw
        df_crops["municipio_tmp"] = df_crops["municipio"].astype(str).str.st
        df_crops["cultivo_tmp"] = df_crops["cultivo"].astype(str).str.strip(
        df_raw["municipio_tmp"] = df_raw["municipio"].astype(str).str.strip(
        df_raw["cultivo_tmp"] = df_raw["cultivo"].astype(str).str.strip().st
        df_sub = df_crops[["anio", "municipio_tmp", "cultivo_tmp"]] + cols_to
        df_raw = pd.merge(df_raw, df_sub, on=["anio", "municipio_tmp", "cult

if "produccion_toneladas" not in df_raw.columns:
    if "hectareas_cosechadas" in df_raw.columns and "rendimiento_toneladas_h
        df_raw["produccion_toneladas"] = df_raw["hectareas_cosechadas"] * df
    else:
        df_raw["produccion_toneladas"] = 0.0

if "rendimiento_toneladas_ha" not in df_raw.columns:
    df_raw["rendimiento_toneladas_ha"] = np.where(
        df_raw["hectareas_cosechadas"] > 0,
        df_raw["produccion_toneladas"] / df_raw["hectareas_cosechadas"],
        np.nan
    )

if "precio_promedio_anual_sipsa" not in df_raw.columns or df_raw["precio_pro
    cons_path = Path('../data/dataset_consolidado_valle.csv') if Path('../da
    if cons_path.exists():
        df_prices = pd.read_csv(cons_path)
        p_col = "precio_promedio_anual_sipsa" if "precio_promedio_anual_sips
        c_col = "cultivo" if "cultivo" in df_prices.columns else ("nombre_cu
        if p_col and c_col and "anio" in df_prices.columns:
            df_prices["cultivo_clean"] = df_prices[c_col].astype(str).str.st
            df_sub_price = df_prices[["anio", "cultivo_clean", p_col]].renam
            if "precio_promedio_anual_sipsa" in df_raw.columns:

```

```

        df_raw = df_raw.drop(columns=["precio_promedio_anual_sipsa"])
        df_raw = pd.merge(df_raw, df_sub_price, on=["anio", "cultivo"],

if "precio_promedio_anual_sipsa" not in df_raw.columns:
    df_raw["precio_promedio_anual_sipsa"] = np.nan

num_cols = ['hectareas_seembradas', 'hectareas_cosechadas', 'produccion_tonel
for col in num_cols:
    if col in df_raw.columns:
        df_raw[col] = pd.to_numeric(df_raw[col].astype(str).str.replace(', ',

df = df_raw[df_raw['anio'] >= 2015].copy()

# Estandarización de grupos
if 'tipo_cultivo' in df.columns:
    df['tipo_cultivo_clean'] = df['tipo_cultivo'].astype(str).str.strip().st
else:
    df['tipo_cultivo_clean'] = "General"

mapping_grupos = {
    'Cultivos Tropicales Tradicionales': 'Tropicales Tradicionales',
    'Cultivos Tropicales Tradicionales ': 'Tropicales Tradicionales',
    'Raíces Y Tubérculos': 'Raíces y Tubérculos',
    'Cultivos Para Condimentos Y Bebidas Medicinales Y Aromáticas': 'Aromáti
    'Cultivos Para Condimentos, Bebidas Medicinales Y Aromáticas': 'Aromáti
}
df['grupo_cultivo'] = df['tipo_cultivo_clean'].replace(mapping_grupos)

df['kilos_cosechados'] = df['produccion_toneladas'] * 1000.0
df['valor_venta'] = df['kilos_cosechados'] * df['precio_promedio_anual_sipsa
df['valor_venta_millones'] = df['valor_venta'] / 1e6

df_val = df[(df['kilos_cosechados'] > 0) & (df['valor_venta_millones'] > 0)]
df_rend_val = df[(df['rendimiento_toneladas_ha'] > 0) & (df['rendimiento_tor

muns_evaluados = sorted(df['municipio'].dropna().unique().tolist())

print(f"Dataset cargado (2015-2024). Registros totales: {len(df):,}")
print(f"Registros con Valor Venta (Precios SIPSA válidos): {df['valor_venta'
print(f"Todos los Municipios evaluados: {len(muns_evaluados)} | Todos los Cu

```

Cargando dataset desde: ../data/silver_agri_modelo_base.csv

Dataset cargado (2015-2024). Registros totales: 11,782

Registros con Valor Venta (Precios SIPSA válidos): 4,035

Todos los Municipios evaluados: 42 | Todos los Cultivos evaluados: 91

1. Valor de Venta Estimado por Municipio y sus Varios Cultivos

Analizamos la totalidad de las parejas (municipio - cultivo) en generación de ingreso bruto acumulado (\$COP\$).

```

In [2]: resumen_mun_prod = df.groupby(['municipio', 'cultivo']).agg(
        anios_registrados=('anio', 'count'),

```

```


total_hectareas_cosechadas=('hectareas_cosechadas', 'sum'),
total_produccion_toneladas=('produccion_toneladas', 'sum'),
total_kilos_cosechados=('kilos_cosechados', 'sum'),
rendimiento_promedio_ton_ha=('rendimiento_toneladas_ha', 'mean'),
precio_promedio_sipsa=('precio_promedio_anual_sipsa', 'mean'),
total_valor_venta_millones=('valor_venta_millones', 'sum')
).reset_index()

top_ingreso = resumen_mun_prod.dropna(subset=['precio_promedio_sipsa']).sort
top_ingreso['mun_cultivo'] = top_ingreso['municipio'] + ' - ' + top_ingreso[

plt.figure(figsize=(16, 9))
sns.barplot(data=top_ingreso.head(25), x='total_valor_venta_millones', y='mu
plt.title('Top 25 Parejas (Municipio - Cultivo) por Valor de Venta Estimado
plt.xlabel('Valor Venta Estimado (Millones COP)', fontsize=12)
plt.ylabel('Pareja (Municipio - Cultivo)', fontsize=12)
h, l = plt.gca().get_legend_handles_labels()
if h:
    plt.legend(h, l, title='Cultivo', bbox_to_anchor=(1.05, 1), loc='upper l
plt.tight_layout()
plt.show()

print(f"--- Resumen de TODAS las Parejas (Municipio - Cultivo) Evaluadas ({l
display(top_ingreso[['municipio', 'cultivo', 'total_kilos_cosechados', 'prec

```



--- Resumen de TODAS las Parejas (Municipio - Cultivo) Evaluadas (500 parejas con precio SIPSA) ---

	municipio	cultivo	total_kilos cosechados	precio_promedio_sipsa	total_valor_v
641	Jamundí	Arroz	171495000.0	2850.227778	
1046	Sevilla	Banano	173504000.0	1124.995556	
1040	Sevilla	Aguacate	61840600.0	3593.898000	
1187	Tuluá	Papa	63471000.0	1677.997143	
132	Bolívar	Lulo	27430000.0	2890.872222	
...	...	...	...	...	
749	La Victoria	Habichuela	2500.0	3240.500000	
1297	Yotoco	Arveja	2000.0	3152.750000	
750	La Victoria	Lechuga	2500.0	1260.920000	
532	El Águila	Repollo	6250.0	620.000000	
760	La Victoria	Pepino	400.0	1347.580000	

500 rows × 5 columns



2. Diagramas de Dispersión Municipio a Municipio: Todos los Municipios y Todos sus Cultivos

Evaluamos para los **42 municipios del departamento** (en subplots independientes por cada territorio) las relaciones de **Kilos Cosechados vs. Valor Venta y Rendimiento (Ton/Ha) vs. Precio SIPSA (\$/Kg)** para la totalidad de sus cultivos.

```
In [3]: # Función auxiliar para renderizar todos los 42 municipios y todos sus cultivos
def plot_grid_completo(df_data, x_col, y_col, x_label, y_label, title, use_log_x, use_log_y):
    n_muns = len(muns_evaluados)
    n_cols = 6
    n_rows = (n_muns + n_cols - 1) // n_cols
    fig, axes = plt.subplots(n_rows, n_cols, figsize=(24, 3.8 * n_rows))
    axes = axes.flatten()

    for idx, mun in enumerate(muns_evaluados):
        df_m = df_data[df_data['municipio'] == mun]
        if len(df_m) > 0:
            sns.scatterplot(ax=axes[idx], data=df_m, x=x_col, y=y_col, hue='cultivo')
            if draw_ony_line:
                axes[idx].axvline(0, color='red', linestyle='--', alpha=0.5)
            if use_log_x:
                axes[idx].set_xscale('log')
            if use_log_y:
                axes[idx].set_yscale('log')
```

```

        h, l = axes[idx].get_legend_handles_labels()
        if h:
            axes[idx].legend(h, l, bbox_to_anchor=(1.02, 1), loc='upper
axes[idx].set_title(f'{mun}', fontsize=10, fontweight='bold')
axes[idx].set_xlabel(x_label, fontsize=8)
axes[idx].set_ylabel(y_label, fontsize=8)

    for j in range(idx + 1, len(axes)):
        axes[j].axis('off')


plt.suptitle(title, fontsize=16, fontweight='bold', y=1.01)
plt.tight_layout()
plt.show()

# Dispersión 1: Kilos Cosechados vs. Valor Venta (Todos los Municipios y Cul
plot_grid_completo(df_val, 'kilos_cosechados', 'valor_venta_millones', 'Kil
'Dispersión 1 (Todos los 42 Municipios y Cultivos): Kilos

# Dispersión 2: Rendimiento vs. Precio SIPSA (Todos los Municipios y Cultivo
plot_grid_completo(df_rend_val.dropna(subset=['precio_promedio_anual_sipsa']
'Rendimiento (Ton/Ha)', 'Precio SIPSA ($/Kg Log)',
'Dispersión 2 (Todos los 42 Municipios y Cultivos): Rendi

```

Dispersión 1 (Todos los 42 Municipios y Cultivos): Kilos Cosechados vs. Valor Venta



Dispersión 2 (Todos los 42 Municipios y Cultivos): Rendimiento vs. Precio SIPSA




3. Diagramas de Dispersión Municipio a Municipio: Hectáreas Cosechadas e Índice Climático ONI

Analizamos en la totalidad de los municipios el comportamiento de las hectáreas cosechadas y el efecto del índice climático ONI sobre todos sus cultivos.

In [4]: `# Dispersión 3: Hectáreas Cosechadas vs. Valor Venta (Todos los Municipios y`
`plot_grid_completo(df_val, 'hectareas_cosechadas', 'valor_venta_millones', '`
`'Dispersión 3 (Todos los 42 Municipios y Cultivos): Hectá`

Dispersión 4 (Todos los 42 Municipios y Cultivos): Índice ONI vs. Valor Venta



4. Sensibilidad Climática ONI Municipio a Municipio: Rendimiento Agrícola (Ton/Ha) por Cultivo


Evaluamos el rendimiento de la totalidad de cultivos en todos los municipios frente a variaciones climáticas ONI (El Niño, La Niña y Neutro).

In [5]: `# Dispersión 5: Índice ONI vs. Rendimiento Agrícola (Todos los Municipios y`
`plot_grid_completo(df_rend_val, 'promedio_oni', 'rendimiento_toneladas_ha',`
`'Dispersión 5 (Todos los 42 Municipios y Cultivos): Índice`

```

# Boxplot por Todos los Municipios y Cultivos
plt.figure(figsize=(18, 8))
sns.boxplot(data=df_rend_val, x='municipio', y='rendimiento_toneladas_ha', h
plt.title('Distribución del Rendimiento Agrícola (Ton/Ha) por Todos los Muni
plt.xlabel('Municipio', fontsize=12)
plt.ylabel('Rendimiento (Ton/Ha)', fontsize=12)
plt.xticks(rotation=90)
h, l = plt.gca().get_legend_handles_labels()
if h:
    plt.legend(h, l, title='Cultivo', bbox_to_anchor=(1.01, 1), loc='upper r
plt.tight_layout()
plt.show()


```

5. Matrices de Correlación Multivariable por Municipio

Analizamos las matrices de correlación interna para municipios representativos del departamento, observando las dinámicas intervariables entre sus cultivos.

```
In [6]: fig, axes = plt.subplots(3, 3, figsize=(18, 16))
axes = axes.flatten()
cols_corr = ['hectareas_cosechadas', 'produccion_toneladas', 'kilos_cosechados']
nombres_corr = ['Cosechadas', 'Producción', 'Kilos', 'Rendimiento', 'Precio']
muns_matriz = ['Palмира', 'Tuluá', 'Candelaria', 'Sevilla', 'Cartago', 'Dagua']
for idx, mun in enumerate(muns_matriz):
    df_m = df[df['municipio'] == mun][cols_corr].dropna()
    if len(df_m) > 0:
        sns.heatmap(df_m.corr(), ax=axes[idx], annot=True, fmt=".2f", cmap="magma")
        axes[idx].set_title(f'Matriz de Correlación: {mun}', fontsize=11, fontweight='bold')
plt.suptitle('Matrices de Correlación Multivariable por Municipio (2015+)',
             fontweight='bold', fontstyle='italic')
plt.tight_layout()
plt.show()
```



6. Conclusiones y Resumen del EDA Municipio a Municipio por Cultivo (2015-2024)

Q&A

- **¿Por qué la visualización municipio a municipio analizando sus varios cultivos resolvió la interpretación agronómica?**

Cada municipio del Valle del Cauca posee condiciones geográficas y de suelo distintas. Al estructurar el estudio **municipio a municipio** y graficar dentro de cada territorio sus varios cultivos en subplots independientes, se aprecia claramente cómo en **Tuluá** conviven el Tomate y la Habichuela con precios estables, mientras en **Sevilla** predomina el Plátano y el Café, y en **Candelaria** la Caña panelera.

- **¿Qué revelan los diagramas por municipio sobre el rendimiento y precios SIPSA?**

En municipios de ladera (ej. Tuluá, Sevilla, Dagua), los varios cultivos hortícolas y

frutales muestran mayor volatilidad ante el clima ONI que los cultivos extensivos planos de Candelaria o Palmira.

Data Analysis Key Findings

- **Enfoque Municipio a Municipio:** Todos los gráficos de dispersión y correlación utilizan subplots dedicados por municipio mostrando sus distintos cultivos (`hue='cultivo'`).
- **Depuración Agronómica:** Filtro $0 < \text{Rendimiento} \leq 100 \text{ Ton} / \text{Ha}$ aplicado homogéneamente.

Insights or Next Steps

1. **Modelos Predictivos Regionales por Municipio:** Utilizar el dataset agrupado por municipio y cultivo (`data/eda_resumen_municipio_producto.csv`) para personalizar sugerencias agrícolas por municipio.